

TECH SPEC — Disclosure Runtime v0.1

**Статус: READ ONLY ·
ИСТОРИЧЕСКИЙ АРТЕФАКТ**

**Источник:
AI_GOVERNANCE_ARCHITECTUR
E PROOF PACK / SESSION-S200 /
2026-07-02**

**SHA256 оригинала:
5b5572cfd29f1b8316a451de88681e
51c7b748dd9df17ad5a2cb95155a1
2bd34**

ОРИГИНАЛ (verbatim)

TECH SPEC – Disclosure Runtime (v0.1)

Goal:

Implement an enforceable rules-engine that validates HARD
DISCLOSURE responses.

Inputs:

- User command text
- Allowed sources list (chat export, files folder, links)
- Optional HUB config (scope lock, automations default, axioms registry)

Outputs:

- Validated response (pass/fail)
- Reasons (which rule failed)
- Suggested repair (what to add/remove)

Rules Engine:

- Must detect: missing Ограничение/Риск/Решение, missing DISCLOSURE COMPLETE
- Must detect: claims of action without artifact (NO FAKE ACTIONS)
- Must enforce: scope lock (no external references)
- Must enforce: UNKNOWN when fields are absent

Data Model:

- Module {name, version, text, triggers, scope}
- Run {timestamp, hub, since, artifacts[], manifest[]}

Metrics:

- % responses passing validation
- % unknown fields (honesty metric)
- time-to-archive (minutes)

Threat Model:

- Hallucinated actions
- Scope creep
- Silent edits

ПАРАЛЛЕЛИ С V9.6

Элемент v0.1	Наследник в V9.6
Rules Engine (pass/fail + reasons + repair)	SIPA_GUARD_REALITY_CHECK.sh / GUARDIAN
Module {name, version, text, triggers, scope}	BIN/*.sh + .TAG + .sha256
Run {timestamp, hub, since, artifacts[], manifest[]}	BOOT_\${DAY}_\${TS} + MANIFEST.tsv
% responses passing validation	stress test 73-84% результаты
% unknown fields (honesty metric)	FACTS ONLY / UNKNOWN rule

Элемент v0.1	Наследник в V9.6
time-to-archive (minutes)	DAY_CLOSE timing
Hallucinated actions → Threat	NO FAKE ACTIONS (Rule #2)
Scope creep → Threat	SIPA Isolation Principle
Silent edits → Threat	sha256 + .TAG верификация
HUB config (scope lock, automations, axioms)	CLAUDE-BRIEF.md per-session

КЛЮЧЕВЫЕ НАХОДКИ

“% unknown fields (honesty metric)” — метрика честности ИИ. Чем больше UNKNOWN в ответах = тем честнее система. Это было метрикой уже в v0.1 (декабрь 2025). В V9 нет явной метрики — это пробел.

“**Silent edits**” в Threat Model. Тихие правки = изменение без фиксации = нарушение целостности. В V9: sha256 + .TAG на каждом файле = защита от silent edits.

Data Model: Run {timestamp, hub, since, artifacts[], manifest[]} = точная структура BOOT_\${DAY}. timestamp = \${TS}, hub = HUB_NAME, artifacts[] = FIXATION/, manifest[] = MANIFEST.tsv. Это не случайное совпадение — это прямая реализация v0.1 спес.

v0.1 → v1.0 = запланированная следующая версия. V9.6 GRAIL = фактическая v1.0 этой спецификации.